

Санкт-Петербургский государственный университет

Прикладная математика и информатика

ОТЧЕТ

по учебной практике 2 (научно-исследовательской работе)

(семестр 2)

**Многомерные фрактальные границы обучаемости нейросетей:
шаг обучения, инерция, затухание весов
и адаптивные оптимизаторы**

Выполнил:

Бухаров Дмитрий Иванович, группа 25.Б21



Научный руководитель:

профессор, доктор физ.-мат. наук

Мокаев Тимур Наилевич

Кафедра прикладной кибернетики

Санкт-Петербург

2026 г.

Содержание

1	Введение	3
1.1	Контекст и актуальность	3
1.2	Цель и задачи работы	3
1.3	Терминология	4
1.4	Структура работы	4
2	Постановка задачи	4
2.1	Модель и функция потерь	4
2.2	Семейство оптимизаторов	5
2.3	Классификация режимов обучения	5
2.4	Сканирование и измерение размерности	6
2.5	Что именно проверяется	6
3	Обзор литературы	7
3.1	Результаты предыдущей НИР	7
3.2	Фрактальная граница обучаемости	7
3.3	Грань устойчивости и крупные шаги обучения	7
3.4	Методы оптимизации	8
3.5	Фрактальная геометрия и динамические системы	8
3.6	Выводы по обзору	9
4	Теоретический результат: область устойчивости метода с инерцией	9
4.1	Двумерное линейное отображение	9
4.2	Условия устойчивости	9
4.3	Численная проверка	10
4.4	Почему в нелинейном случае граница усложняется	11
5	Объект и методы исследования	12
5.1	Вычислительная схема: ансамблевая векторизация	12
5.2	Протокол экспериментов	13
5.3	Выбор окон сканирования	13
5.4	Последовательность зумов	13
5.5	Программная среда и ресурсы	13
6	Результаты экспериментов	14
6.1	Репликация базового эксперимента	14
6.2	Сечение (η, β) : инерция	15
6.3	Затухание весов и размер батча	17
6.4	Сравнение оптимизаторов	18
6.5	Случайные и структурированные данные	20

6.6	Трёхмерное пространство $(\eta, \beta, \lambda_{wd})$	21
6.7	Последовательность зумов	23
6.8	Влияние численной точности	23
7	Обсуждение	25
7.1	Сводка результатов	25
7.2	О «сглаживании» границы адаптивными методами	26
7.3	Связь с теорией динамики	26
7.4	Ограничения исследования	27
7.5	Практические следствия	28
8	Заключение	29
8.1	Достигнутые результаты	29
8.2	Научная и практическая значимость	30
8.3	Ограничения	30
8.4	Направления дальнейшей работы	30
	Список литературы	32
A	Исходный код	35
A.1	Ансамблевая итерация обучения	35
A.2	Правила обновления	35
A.3	Классификация режимов	36
A.4	Извлечение границы и box-counting	36
A.5	Теоретический блок	37
B	Инструкция по воспроизведению	37
B.1	Структура проекта	37
B.2	Требования	37
B.3	Запуск	38
B.4	Фиксация случайности и точности	38
C	Дополнительные материалы	38

1. Введение

1.1. Контекст и актуальность

В предыдущей научно-исследовательской работе была воспроизведена фрактальная граница обучаемости нейронной сети в двумерном пространстве скоростей обучения слоёв (η_0, η_1) , измерена box-counting размерность границы для активаций tanh, ReLU и линейной сети, а также показана связь наблюдаемой картины с режимами динамики градиентного спуска: монотонной сходимостью, catapult-режимом, периодичностью, хаосом и расходимостью.

Ограничение того исследования очевидно: настоящая практика обучения нейронных сетей почти никогда не сводится к чистому градиентному спуску с двумя шагами обучения. Реальный оптимизатор содержит инерцию (momentum), регуляризацию затуханием весов (weight decay), стохастичность мини-батчей, а на практике чаще всего применяются адаптивные методы — Adam и RMSprop. Поэтому естественный и содержательный вопрос состоит в том, является ли фрактальность границы обучаемости свойством именно «голоого» градиентного спуска, или же она сохраняется и в более реалистичном многомерном пространстве гиперпараметров.

Практическая значимость вопроса связана с автоматическим подбором гиперпараметров. Если граница между успешным и неуспешным обучением остаётся фрактальной при добавлении инерции и регуляризации, то любые методы поиска, опирающиеся на гладкость или липшицевость целевой метрики по гиперпараметрам, принципиально ограничены: на любом масштабе рядом с удачной конфигурацией находится неудачная. Если же адаптивные методы сглаживают границу, это даёт количественный аргумент в пользу их робастности, помимо привычных аргументов о скорости сходимости.

1.2. Цель и задачи работы

Цель работы: исследовать, сохраняется ли фрактальная структура границы обучаемости нейронной сети при переходе от двумерного пространства скоростей обучения к пространству, включающему инерцию, затухание весов, размер батча и параметры адаптивных оптимизаторов, и количественно сравнить сложность границы для разных методов оптимизации.

Задачи:

1. Кратко изложить результаты предыдущей НИР и обзор литературы по фрактальной границе обучаемости, эффекту грани устойчивости и роли крупных шагов обучения.
2. Получить теоретический мини-результат: для квадратичной функции $L(w) = \frac{1}{2}\lambda w^2$ записать градиентный спуск с инерцией в виде двумерного линейного отображения, найти условия локальной устойчивости через собственные значения матрицы перехода и сравнить область устойчивости в плоскости (η, β) с обычным градиентным спуском.

3. Воспроизвести базовый эксперимент предыдущей НИР и построить новые двумерные сечения пространства гиперпараметров: (η, β) , (η, λ_{wd}) , (η, B) , с цветовой картой режимов и оценкой box-counting размерности границы.
4. Сравнить SGD, SGD с инерцией, Adam и RMSprop; проверить гипотезу о том, что адаптивные методы сглаживают фрактальную структуру границы за счёт покоординатной нормализации градиентов.
5. Сравнить границы обучаемости на случайных и на структурированных данных (набор sklearn digits).
6. Построить трёхмерный эксперимент $(\eta, \beta, \lambda_{wd})$ в виде набора двумерных сечений и обсудить, можно ли по сечениям судить о сложности границы в полном трёхмерном пространстве.
7. Обеспечить воспроизводимость: фиксация seed, типа точности, разрешения сетки и критериев классификации режимов; оформление отчёта в L^AT_EX.

1.3. Терминология

Далее используются следующие соответствия терминов: *trainability boundary* — граница обучаемости; *box-counting dimension* — размерность Минковского, или box-counting размерность; *learning rate* — шаг обучения; *momentum* — инерция; *weight decay* — затухание весов, или L_2 -регуляризация; *edge of stability* — грань устойчивости; *catapult effect* — catapult-эффект, или режим выброса.

1.4. Структура работы

В разделе 2 даётся строгая постановка задачи: модель, семейство оптимизаторов, критерии классификации режимов обучения и способ измерения размерности. Раздел 3 содержит обзор литературы. Раздел 4 содержит теоретический результат об области устойчивости метода тяжёлого шарика. Раздел 5 описывает программную реализацию и вычислительный протокол. Раздел 6 представляет результаты экспериментов, раздел 7 — их обсуждение, связь с теорией и ограничения. Раздел 8 подводит итоги.

2. Постановка задачи

2.1. Модель и функция потерь

Рассматривается однослойная полносвязная сеть без смещений

$$f(x; W_0, W_1) = W_1 \sigma(W_0 x), \quad (1)$$

где $x \in \mathbb{R}^{d_{in}}$, $W_0 \in \mathbb{R}^{h \times d_{in}}$, $W_1 \in \mathbb{R}^{d_{out} \times h}$, а σ — поэлементная функция активации ($\tanh$, ReLU либо тождественная). Всюду далее $d_{in} = d_{out} = h = 16$, что даёт $2 \cdot 16 \cdot 16 = 512$ обучаемых параметров.

Функция потерь — среднеквадратичная ошибка на обучающей выборке $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$:

$$L(W_0, W_1) = \frac{1}{Nd_{out}} \sum_{i=1}^N \|f(x_i; W_0, W_1) - y_i\|^2. \quad (2)$$

2.2. Семейство оптимизаторов

Пусть $g_t^{(\ell)} = \nabla_{W_\ell} L(W^{(t)}) + \lambda_{wd} W_\ell^{(t)}$ — градиент по весам слоя $\ell \in \{0, 1\}$ с учётом L_2 -регуляризации (затухание весов реализовано добавлением к градиенту, не в развязанной форме AdamW). Рассматриваются четыре правила обновления.

SGD: $W_\ell^{(t+1)} = W_\ell^{(t)} - \eta g_t^{(\ell)}$.

SGD с инерцией (heavy ball):

$$v_{t+1}^{(\ell)} = \beta v_t^{(\ell)} + g_t^{(\ell)}, \quad W_\ell^{(t+1)} = W_\ell^{(t)} - \eta v_{t+1}^{(\ell)}. \quad (3)$$

RMSprop: $s_{t+1} = \beta_2 s_t + (1 - \beta_2) g_t^{\odot 2}$, $W^{(t+1)} = W^{(t)} - \eta g_t / (\sqrt{s_{t+1}} + \varepsilon)$.

Adam: $m_{t+1} = \beta_1 m_t + (1 - \beta_1) g_t$, $s_{t+1} = \beta_2 s_t + (1 - \beta_2) g_t^{\odot 2}$, с коррекцией смещения $\hat{m} = m_{t+1} / (1 - \beta_1^{t+1})$, $\hat{s} = s_{t+1} / (1 - \beta_2^{t+1})$ и обновлением $W^{(t+1)} = W^{(t)} - \eta \hat{m} / (\sqrt{\hat{s}} + \varepsilon)$, $\varepsilon = 10^{-8}$.

Все операции выполняются послойно, что позволяет задавать отдельные шаги обучения η_0 и η_1 для входного и выходного слоёв.

2.3. Классификация режимов обучения

Пусть $\tilde{L}(t) = L(W^{(t)}) / L(W^{(0)})$ — нормализованный loss. В отличие от предыдущей НИР, где использовалось бинарное деление на сходимость и расходимость, здесь вводится классификация на четыре режима, поскольку при наличии инерции и адаптивных методов ограниченные незатухающие колебания занимают значительную долю пространства гиперпараметров.

Определение 1 (Режимы). Пусть T — число итераций, $\mathcal{T} = \{T - 64, \dots, T - 1\}$ — хвост траектории. Обозначим $m_{\text{кон}} = \frac{1}{20} \sum_{t=T-20}^{T-1} \tilde{L}(t)$, $m_{\text{нач}} = \frac{1}{20} \sum_{t \in \mathcal{T}, t < T-44} \tilde{L}(t)$, а через $\text{rel} = \text{std}_{\mathcal{T}} \tilde{L} / \text{mean}_{\mathcal{T}} \tilde{L}$ — относительный разброс на хвосте. Тогда:

- **NaN/Inf**, если хотя бы на одной итерации $\tilde{L}(t)$ не является конечным числом;
- **расходимость**, если $\max_t \tilde{L}(t) > 10^6$, но переполнения не произошло;
- **сходимость**, если $m_{\text{кон}} < 1$ и при этом либо $\text{rel} < 10^{-3}$ (траектория вышла на стационар), либо $m_{\text{кон}} < 0.99 m_{\text{нач}}$ (loss продолжает убывать);

- **осцилляции/периодичность** — во всех остальных случаях: траектория ограничена, но не сходится (циклы периода 2 и выше, хаотические колебания, стационарные плато выше начального уровня).

Условие $m_{\text{кон}} < 1$ совпадает с критерием сходимости предыдущей НИР; дополнительные условия отделяют от сходимости ограниченные незатухающие режимы. Границей обучаемости далее называется граница множества {сходимость} в пространстве гиперпараметров.

2.4. Сканирование и измерение размерности

Для пары гиперпараметров (p, q) строится прямоугольная сетка $n \times n$ (логарифмическая по шагу обучения и по затуханию весов, равномерная по β , β_1 , β_2 и по размеру батча). Для каждого узла выполняется T итераций обучения из одной и той же фиксированной инициализации, после чего узел относится к одному из четырёх режимов согласно определению 1. Результат — матрица режимов $R \in \{0, 1, 2, 3\}^{n \times n}$.

Граница извлекается морфологически. Пусть $B_{ij} = [R_{ij} = \text{сходимость}]$. Тогда

$$\partial B = \text{Dilation}(B) \oplus \text{Erosion}(B), \quad (4)$$

где $\oplus$ — симметрическая разность (XOR), после чего применяется скелетонизация до толщины в один пиксель.

Box-counting размерность оценивается стандартно [19]: для последовательности размеров ячеек $\varepsilon_k = 2^k$, $k = 1, \dots, \lfloor \log_2 n \rfloor - 2$, подсчитывается число $N(\varepsilon_k)$ непустых ячеек, покрывающих ∂B , и

$$D_{\text{box}} = -\text{slope}(\text{МНК-регрессия } \log N(\varepsilon) \text{ по } \log \varepsilon). \quad (5)$$

В качестве погрешности σ_D приводится стандартная ошибка наклона регрессии; она характеризует только качество линейной аппроксимации в координатах $\log \varepsilon$ – $\log N$ и не учитывает систематическую зависимость оценки от разрешения сетки, которая обсуждается отдельно в разделе 7.4.

2.5. Что именно проверяется

Формально исследуются следующие гипотезы:

1. фрактальность границы сохраняется в сечении (η, β) , то есть добавление инерции не делает границу гладкой кривой;
2. затухание весов и увеличение размера батча уменьшают D_{box} ;
3. адаптивные методы (Adam, RMSprop) дают меньшую D_{box} , чем SGD, в сопоставимых сечениях;
4. структурированные данные не разрушают фрактальность границы.

3. Обзор литературы

3.1. Результаты предыдущей НИР

В предыдущей работе была реализована процедура сканирования двумерного пространства (η_0, η_1) для однослойной сети, введён бинарный критерий сходимости (среднее нормализованного loss по последним 20 итерациям меньше единицы) и построены цветовые карты обучаемости для активаций tanh, ReLU и линейной сети. Измеренные box-counting размерности составили 1.547 для tanh, 1.612 для ReLU и 1.183 для линейной сети; последовательность из семи уровней зума дала медианную размерность 1.548 при стандартном отклонении 0.009. На игрушечной задаче квадратичной регрессии были воспроизведены пять фаз динамики: монотонная сходимость, catapult, периодические орбиты, хаос и расходимость. Настоящая работа наследует программную архитектуру и метод измерения размерности, но расширяет пространство гиперпараметров и уточняет классификацию режимов.

3.2. Фрактальная граница обучаемости

Явление было обнаружено и описано Sohl-Dickstein [1]. Основное наблюдение состоит в том, что множество гиперпараметров, при которых обучение сходится, имеет границу с самоподобной структурой, наблюдаемой на многих порядках масштаба, а измеренные размерности лежат в диапазоне примерно от 1.1 до 2.0 в зависимости от активации и выбранной пары гиперпараметров. Ключевой аргумент состоит в аналогии: обучение — это итерация отображения в пространстве параметров, а классические фракталы (множество Мандельброта, множества Жюлиа) возникают именно как границы областей ограниченности при итерации простых отображений.

Torkamandi и соавторы [2] перенесли эксперимент на трансформерные архитектуры типа decoder-only, обучаемые оптимизатором Adam, и получили фрактальные границы с размерностями порядка 1.5–2.0, что указывает на универсальность явления и на то, что адаптивные методы сами по себе фрактальность не устраняют. Liu, Arnould и Sohl-Dickstein [3] показали, что для возникновения фрактальной границы достаточно тривиальной невыпуклости: добавление косинусоидального возмущения к квадратичной функции потерь уже порождает фрактальную границу, причём размерность растёт с «шероховатостью» возмущения. Это важно методологически: наблюдаемая фрактальность не требует ни глубины сети, ни большого объёма данных.

3.3. Грань устойчивости и крупные шаги обучения

Cohen и соавторы [4] обнаружили, что при полнобатчевом обучении максимальное собственное значение гессиана растёт до величины $2/\eta$ и далее стабилизируется около этого порога, а loss становится немонотонным на коротких масштабах, продолжая

убывать на длинных. Этот режим получил название грани устойчивости. Он объясняет, почему наилучшие по скорости конфигурации располагаются вблизи границы обучаемости, а не в глубине области сходимости. В последующей работе [5] тот же эффект был описан и для адаптивных методов, где роль порога играет предобусловленная резкость; это делает нетривиальным вопрос о том, сглаживает ли Adam границу.

Lewkowycz и соавторы [6] описали catapult-механизм: при достаточно крупном шаге loss сначала растёт, а затем система переходит в область меньшей кривизны и сходимость восстанавливается. Kong и Tao [7] показали, что детерминированный градиентный спуск с крупным шагом на многомасштабной целевой функции ведёт себя стохастически: если шаг разрешает макромасштаб, но не микромасштаб, динамика становится хаотической и возникают эффекты, аналогичные шуму SGD. Chen и соавторы [8] провели детальный анализ квадратичной регрессии, где увеличение шага последовательно приводит систему через монотонную сходимость, catapult, периодические орбиты, хаос по Ли–Йорке [10] и расходимость. Универсальный сценарий перехода к хаосу через каскад удвоения периода описан Feigenbaum [9].

3.4. Методы оптимизации

Метод тяжёлого шарика предложен Поляком [11]; ускоренный метод с иной схемой экстраполяции — Нестеровым [12]. Adam введён Kingma и Ba [13], RMSprop — Tieleman и Hinton [14]. Loshchilov и Hutter [15] показали, что для адаптивных методов существенно, добавляется ли затухание весов к градиенту или применяется развязанно; в настоящей работе используется первый, классический вариант, что необходимо учитывать при сопоставлении результатов. Обзор методов оптимизации для крупномасштабного машинного обучения дан в работе Bottou, Curtis и Nocedal [16]; связь размера батча и шага обучения исследована Smith и соавторами [17]. Систематическое изложение архитектур, активаций и алгоритмов обучения содержится в монографии Goodfellow, Bengio и Courville [18].

3.5. Фрактальная геометрия и динамические системы

Математические основы фрактальной геометрии и определения размерности, включая размерность Минковского–Булиганда, изложены у Falconer [19]; классическое изложение с акцентом на природные примеры дано Mandelbrot [20]. Теория нелинейных динамических систем, бифуркации и переход к хаосу описаны у Strogatz [21]. Практические аспекты подсчёта box-counting размерности по бинарным изображениям и типичные источники систематической ошибки рассмотрены в документации пакета PoreSpy [22].

3.6. Выводы по обзору

Литература устанавливает, что фрактальность границы обучаемости — устойчивое явление, наблюдаемое от простейших невыпуклых функций до трансформеров, и что оно тесно связано с динамикой вблизи грани устойчивости. Однако систематического сравнения сложности границы между оптимизаторами в сопоставимых сечениях пространства гиперпараметров в доступной литературе не обнаружено; в частности, вопрос о том, сглаживает ли покоординатная нормализация градиентов границу, остаётся открытым. Настоящая работа предоставляет количественные данные по этому вопросу.

4. Теоретический результат: область устойчивости метода с инерцией

4.1. Двумерное линейное отображение

Рассмотрим скалярную квадратичную функцию потерь

$$L(w) = \frac{1}{2}\lambda w^2, \quad \lambda > 0, \quad (6)$$

и градиентный спуск с инерцией в форме (3), где $\nabla L(w) = \lambda w$:

$$v_{t+1} = \beta v_t + \lambda w_t, \quad w_{t+1} = w_t - \eta v_{t+1}. \quad (7)$$

Подставляя первое равенство во второе, получаем $w_{t+1} = w_t - \eta(\lambda w_t + \beta v_t) = (1 - \eta\lambda)w_t - \eta\beta v_t$. Следовательно, пара (w_t, v_t) подчиняется линейному отображению

$$\begin{pmatrix} w_{t+1} \\ v_{t+1} \end{pmatrix} = M \begin{pmatrix} w_t \\ v_t \end{pmatrix}, \quad M = \begin{pmatrix} 1 - \eta\lambda & -\eta\beta \\ \lambda & \beta \end{pmatrix}. \quad (8)$$

4.2. Условия устойчивости

Предложение 1 (Область устойчивости метода тяжёлого шарика). Пусть $x := \eta\lambda$. Нулевое решение отображения (8) асимптотически устойчиво тогда и только тогда, когда

$$|\beta| < 1 \quad \text{и} \quad 0 < x < 2(1 + \beta). \quad (9)$$

При $\beta = 0$ условие переходит в классическое условие устойчивости градиентного спуска $0 < \eta\lambda < 2$.

Доказательство. Вычислим инварианты матрицы M :

$$\text{tr } M = 1 - \eta\lambda + \beta = 1 + \beta - x, \quad (10)$$

$$\det M = (1 - \eta\lambda)\beta + \eta\beta\lambda = \beta - \eta\lambda\beta + \eta\lambda\beta = \beta. \quad (11)$$

Существенно, что определитель не зависит от шага обучения и равен коэффициенту инерции; это отражает тот факт, что инерция задаёт скорость сжатия фазового объёма.

Характеристический полином имеет вид $p(\mu) = \mu^2 - T\mu + \Delta$, где $T = \text{tr } M$, $\Delta = \det M = \beta$. Асимптотическая устойчивость равносильна тому, что оба корня лежат строго внутри единичной окружности. По критерию Жюри для полинома второй степени это эквивалентно системе

$$|\Delta| < 1, \quad p(1) > 0, \quad p(-1) > 0, \quad (12)$$

то есть

$$|\beta| < 1, \quad 1 - T + \beta > 0, \quad 1 + T + \beta > 0. \quad (13)$$

Подставляя $T = 1 + \beta - x$, получаем из второго неравенства $1 - 1 - \beta + x + \beta = x > 0$, а из третьего $1 + 1 + \beta - x + \beta = 2 + 2\beta - x > 0$, то есть $x < 2(1 + \beta)$. Вместе с $|\beta| < 1$ это в точности (9). $\square$

Следствие 1 (Характер сходимости). *Корни комплексны при $T^2 < 4\Delta$, то есть при $(1 + \beta - x)^2 < 4\beta$. В этом случае*

$$|\mu_{1,2}| = \sqrt{\Delta} = \sqrt{\beta}, \quad (14)$$

и скорость сходимости не зависит от λ : все собственные направления затухают с одинаковым множителем $\sqrt{\beta}$ за итерацию. Это объясняет осцилляторный характер траекторий при больших β и то, почему инерция выравнивает скорости сходимости вдоль направлений с разной кривизной.

Следствие 2 (Расширение допустимого шага). *Максимальный устойчивый шаг равен $\eta_{\max}(\beta) = 2(1 + \beta)/\lambda$, что при $\beta \rightarrow 1$ вдвое превышает соответствующее значение для градиентного спуска. Порог грани устойчивости для метода с инерцией, таким образом, есть $\lambda_{\max}(\nabla^2 L) \approx 2(1 + \beta)/\eta$.*

4.3. Численная проверка

На рис. 1 слева показан спектральный радиус $\rho(M)$ в плоскости (x, β) с нанесённой аналитической границей $x = 2(1 + \beta)$; справа — множество пар, для которых численная итерация (7) из начального условия $w_0 = 1$, $v_0 = 0$ за 400 шагов даёт $|w_{400}| < 10^{-3}$. Численная область устойчивости совпадает с аналитической с точностью до разрешения сетки, что подтверждает предложение 1. Вертикальная пунктирная линия $x = 2$ отмечает порог обычного градиентного спуска: вся область правее неё и левее красной кривой — это шаги, устойчивые только благодаря инерции.




Рис. 1. Область устойчивости метода тяжёлого шарика на квадратичной функции. Слева — спектральный радиус матрицы перехода (значения обрезаны сверху на уровне 2); белая линия — уровень $\rho = 1$, красная штриховая — аналитическая граница $\eta\lambda = 2(1 + \beta)$. Справа — численно определённая область устойчивости.

4.4. Почему в нелинейном случае граница усложняется

Предложение 1 даёт гладкую границу: в плоскости (x, β) это прямая. Однако три обстоятельства разрушают эту гладкость при переходе к нейронной сети.

Во-первых, в многомерном случае L имеет спектр кривизн $\lambda_1, \dots, \lambda_d$, и условие устойчивости должно выполняться одновременно для всех мод: $\eta\lambda_i < 2(1 + \beta)$. Граница области устойчивости определяется максимальным собственным значением гессиана, которое само зависит от точки в пространстве параметров, а значит — от всей предыстории траектории.

Во-вторых, при обучении нейронной сети гессиан не постоянен: система, вышедшая за порог устойчивости по одной моде, не обязана расходиться, поскольку может перейти в область меньшей кривизны (catapult-механизм [6]) и стабилизироваться на грани устойчивости [4]. Итоговый исход зависит от того, успеет ли траектория попасть в такую область раньше, чем норма весов достигнет переполнения; это делает исход чувствительным к сколь угодно малым изменениям гиперпараметров.

В-третьих, при потере устойчивости неподвижной точки нелинейная система не уходит на бесконечность сразу, а проходит через каскад удвоения периода [9] и хаос. На рис. 2 показана бифуркационная диаграмма для скалярной нелинейной задачи $L(w) = \frac{1}{2}(w^2 - y)^2$ при трёх значениях инерции. Видно, что рост β смещает каскад бифуркаций в область меньших η и делает переход более резким: при $\beta = 0.9$ окно устойчивого поведения по η существенно сужается, хотя для квадратичной модели инерция допустимый шаг, наоборот, расширяет. Это принципиальное различие между линейным и нелинейным случаем и объясняет, почему граница, гладкая в теории для

квадратики, становится изрезанной для сети.




Рис. 2. Бифуркационная диаграмма для нелинейной скалярной задачи $L(w) = \frac{1}{2}(w^2 - y)^2$ при $y = 1$: показаны последние 120 из 600 итераций для каждого η . Слева направо: $\beta = 0$, $\beta = 0.5$, $\beta = 0.9$.

5. Объект и методы исследования

5.1. Вычислительная схема: ансамблевая векторизация

Прямолинейная реализация сканирования требует обучить n^2 сетей независимо; при $n = 512$ и $T = 400$ это 10^8 итераций и, в наивном цикле, десятки часов машинного времени. В настоящей работе используется другая схема: все узлы сетки обучаются *одновременно* как ансамбль независимых сетей.

Веса хранятся в тензорах формы (G, h, d_{in}) и (G, d_{out}, h) , где G — число конфигураций в текущем блоке, а гиперпараметры — в векторах формы $(G,)$, транслируемых по осям весов. Прямой и обратный проход записываются через пакетные свёртки индексов:

$$H = \text{einsum}('nd,ghd->gnh', X, W0); \quad gW0 = \text{einsum}('gnh,nd->ghd', gh, X)$$

и так далее. Это сводит всю итерацию к нескольким вызовам BLAS и даёт ускорение примерно на два порядка по сравнению с поэлементным циклом. Расчёт ведётся блоками по 4096 конфигураций, что ограничивает пик потребления памяти примерно 200 МБ.

Градиенты вычисляются вручную (без автоматического дифференцирования), что обеспечивает полный контроль над порядком операций и, следовательно, побитовую воспроизводимость. Конфигурации, достигшие переполнения, не исключаются из расчёта, но их градиенты обнуляются через `nan_to_num`, чтобы переполнение в одной конфигурации не портило соседние через общие арифметические операции; факт переполнения при этом запоминается и определяет режим NaN/Inf.

5.2. Протокол экспериментов

Общие параметры, если не указано иное: $d_{in} = d_{out} = h = 16$; инициализация весов нормальным распределением с масштабом 1.0, одна и та же для всех узлов сетки; число итераций $T = 400$; тип данных `float64`; разрешение сетки 256×256 , для двух опорных карт — 512×512 .

Базовый набор данных — одна обучающая пара ($|\mathcal{D}| = 1$) со случайными x и y из стандартного нормального распределения. Этот выбор унаследован от работы [1], где случай $|\mathcal{D}| = 1$ рассматривается как минимальный, в котором явление уже наблюдается, и не осложнён усреднением по выборке. Для экспериментов с мини-батчами и со структурированными данными используются наборы из 32 и 16 примеров соответственно.

Набор `sklearn digits` преобразуется следующим образом: изображения 8×8 разворачиваются в векторы длины 64, центрируются, проецируются на первые 16 главных компонент всей выборки и нормируются на единичное стандартное отклонение; целевые векторы — one-hot представление класса в $\{-1, +1\}^{16}$. Такое преобразование позволяет использовать ту же архитектуру, что и для случайных данных, и делает сравнение корректным.

5.3. Выбор окон сканирования

Порог устойчивости зависит от кривизны функции потерь, а та — от активации, объёма данных и оптимизатора. Поэтому единое окно по η для всех конфигураций непригодно: например, для ReLU при $|\mathcal{D}| = 1$ во всём диапазоне $\eta \in [10^{-2}, 10]$ доля сходимости составляет 0.99, то есть граница просто не попадает в окно. Окна подбирались так, чтобы граница находилась внутри области сканирования, а доли режимов были нетривиальны. Конкретные диапазоны указаны при каждом эксперименте; следствия этого выбора для сопоставимости оценок обсуждаются в разделе 7.4.

5.4. Последовательность зумов

Центр зума выбирается автоматически, а не вручную: по опорной карте (η, β) вычисляется бинарная граница, к ней применяется усредняющий фильтр 41×41 , и центром объявляется точка максимума плотности границы, удалённая не менее чем на 64 пикселя от краёв. Для базовой карты это дало точку $\eta^* \approx 0.369$, $\beta^* \approx 0.300$. На уровне k окно сжимается вдвое по $\log_{10} \eta$ и по β относительно центра.

5.5. Программная среда и ресурсы

Реализация выполнена на Python 3.12 с использованием NumPy (линейная алгебра), SciPy (морфологические операции), scikit-image (скелетонизация), scikit-learn (набор `digits`) и Matplotlib (визуализация). PyTorch не использовался: в целевой

вычислительной среде он недоступен, а ансамблевая векторизация на NumPy оказалась достаточной по производительности. Вычисления проводились на одном ядре CPU; суммарное машинное время всех экспериментов, вошедших в отчёт, составило 1.0 ч.

Воспроизводимость обеспечивается фиксацией: seed генератора случайных чисел (42 для данных, $42 + 1000$ для инициализации весов, $42 + 7$ для порядка примеров в мини-батчах), типа точности, разрешения сетки, числа итераций и порогов классификации режимов. Все параметры каждого запуска сохраняются в JSON рядом с результатом, а числа в таблицах и в тексте настоящего отчёта подставляются автоматически из этих файлов, что исключает расхождение между текстом и данными.

6. Результаты экспериментов

6.1. Репликация базового эксперимента

На рис. 3 представлена карта обучаемости для базовой конфигурации ($\tanh$, $|\mathcal{D}| = 1$, полный батч, разрешение 512×512). Слева — карта четырёх режимов, справа — непрерывная сине-красная карта в стиле предыдущей НИР, где насыщенность синего пропорциональна сумме нормализованных loss по итерациям, а красного — обратной величине.




Рис. 3. Базовая карта обучаемости в плоскости (η_0, η_1) , активация $\tanh$, разрешение 512×512 , $T = 400$ итераций.

Качественная картина воспроизводит результат предыдущей НИР: существуют протяжённые связные области успешного обучения, граница между ними и областью расходимости не является гладкой кривой, а оптимальные по скорости конфигурации располагаются вблизи границы. Существенное отличие от предыдущей работы состоит в том, что значительную часть карты занимает режим ограниченных незатухающих колебаний (доля 0.49 приходится на сходимость), который при бинарном критерии предыдущей НИР был бы отнесён к сходимости.

Измеренная размерность границы составила $D_{\text{box}} = 1.688 \pm 0.035$.

Сравнение активаций осложняется тем, что порог устойчивости у них различен (см. табл. 1). В общем окне $\eta \in [10^{-2}, 10]$ для ReLU при $|\mathcal{D}| = 1$ доля сходимости равна 0.99, а для линейной сети, наоборот, 0.07: граница выходит за пределы окна. Поэтому дополнительно выполнены прогоны в окнах, центрированных на собственном пороге каждой конфигурации, и прогоны на общем наборе из 32 примеров, где сравнение активаций корректно: tanh даёт 1.433, ReLU — 1.282.

Таблица 1. Размерность границы для разных активаций и окон сканирования. Столбцы «сход.», «осц.», «расх.», «NaN» — доли соответствующих режимов.

Активация	Окно по η	D_{box}	сход.	осц.	расх.	NaN
tanh	$[10^{-2}, 10]$, $ \mathcal{D} = 1$, 512 ²	1.688 ± 0.035	0.49	0.19	0.06	0.26
ReLU	$[10^{-2}, 10]$, $ \mathcal{D} = 1$	1.160 ± 0.008	0.99	0.01	0.00	0.00
линейная	$[10^{-2}, 10]$, $ \mathcal{D} = 1$	1.512 ± 0.067	0.07	0.02	0.00	0.91
линейная	$[10^{-4}, 10^{-1}]$, $ \mathcal{D} = 1$	1.565 ± 0.033	0.75	0.15	0.00	0.10
tanh	$[10^{-1}, 10^3]$, $ \mathcal{D} = 32$	1.433 ± 0.050	0.38	0.07	0.02	0.54
ReLU	$[10^{-3}, 10]$, $ \mathcal{D} = 32$	1.282 ± 0.045	0.47	0.11	0.00	0.43
ReLU	$[10^{-1}, 10^3]$, $ \mathcal{D} = 32$	1.074 ± 0.010	0.06	0.00	0.00	0.94

Рис. 4 показывает карты для трёх активаций в общем окне; хорошо видно, что для ReLU граница в это окно не попадает.




Рис. 4. Карты режимов для активаций tanh, ReLU и линейной в общем окне $\eta \in [10^{-2}, 10]$.

Линейность зависимости $\log N(\varepsilon)$ от $\log \varepsilon$, подтверждающая применимость оценки (5), показана на рис. 5.

6.2. Сечение (η, β) : инерция

Центральный результат работы представлен на рис. 6: сечение пространства гиперпараметров по шагу обучения и коэффициенту инерции при общем для обоих слоёв η .

Измеренная размерность $D_{\text{box}} = 1.695 \pm 0.033$ совпадает в пределах погрешности с размерностью базовой карты (η_0, η_1) , равной 1.688 ± 0.035 . Таким образом, добавление




Рис. 5. Box-counting: зависимость числа непустых ячеек от размера ячейки в логарифмических координатах для базовой карты и для сечения (η, β) .




Рис. 6. Сечение (η, β) для SGD с инерцией, разрешение 512×512 . Справа — извлечённая скелетонизированная граница множества сходимости.

инерции не делает границу обучаемости гладкой: первая из проверяемых гипотез подтверждается.


Структура карты согласуется с теорией раздела 4. При малых η обучение сходится при любом β ; при росте η система сначала входит в область ограниченных колебаний, и лишь затем — в область переполнения. Граница области сходимости смещается влево с ростом β , что отражает увеличение эффективного шага: в стационарном режиме накопленная скорость в схеме (3) превышает мгновенный градиент в $1/(1 - \beta)$ раз. При $\beta \gtrsim 0.8$ область незатухающих колебаний практически исчезает, уступая место резкому переходу от сходимости к переполнению.

6.3. Затухание весов и размер батча


Результаты для сечения (η, λ_{wd}) и для мини-батчей сведены в табл. 2 и 3, карты приведены на рис. 7–8.

Таблица 2. Размерность границы в основных сечениях (разрешение 256×256 , кроме отмеченных отдельно).

Конфигурация	D_{box}	сход.	осц.	расх.	NaN
(η_0, η_1) , SGD	1.633 ± 0.041	0.49	0.19	0.06	0.26
(η, β) , momentum	1.695 ± 0.033	0.52	0.21	0.05	0.23
(η, λ_{wd}) , SGD	1.153 ± 0.035	0.45	0.22	0.07	0.26



(a) сечение (η, λ_{wd})



(b) сечение (η, B)

Рис. 7. Влияние затухания весов и размера батча.

Затухание весов заметно сглаживает границу: $D_{\text{box}} = 1.153 \pm 0.035$ против 1.633 ± 0.041 для карты (η_0, η_1) при том же разрешении. Механизм прозрачен: слагаемое $\lambda_{wd}W$ добавляет к гессиану изотропный сдвиг $\lambda_{wd}I$, что при больших λ_{wd} подавляет различие между направлениями разной кривизны и делает порог устойчивости почти не зависящим от точки в пространстве параметров.

Для сечения (η, B) карта режимов построена (рис. 7б), однако размерность по нему не оценивалась: полоса 512×32 не даёт достаточного числа масштабов ε для устойчивой регрессии (5), и результат оказывается неопределённым. Вместо этого влияние размера батча измерено по полноценным картам (η_0, η_1) при фиксированных B .

Таблица 3. Влияние размера мини-батча ($|\mathcal{D}| = 32, \tanh$).

Конфигурация	D_{box}	сход.	осц.	расх.	NaN
$B = 1$	1.722 ± 0.074	0.17	0.09	0.13	0.61
$B = 4$	1.568 ± 0.050	0.30	0.08	0.09	0.53
$B = 32$ (полный батч)	1.433 ± 0.050	0.38	0.07	0.02	0.54




Рис. 8. Карты обучаемости при разных размерах мини-батча.

Наблюдается монотонный тренд: $B = 1$ даёт 1.722, $B = 4$ — 1.568, полный батч $B = 32$ — 1.433. Уменьшение батча увеличивает изрезанность границы. Это согласуется с интерпретацией [7]: стохастичность выборки играет роль дополнительного мелкомасштабного возмущения целевой функции, а по результатам [3] именно мелкомасштабная невыпуклость и порождает фрактальную границу. Вторая гипотеза, таким образом, подтверждается для размера батча, но в части затухания весов — лишь при достаточно больших λ_{wd} (см. ниже раздел 6.6).

6.4. Сравнение оптимизаторов

Результаты сравнения четырёх методов приведены в табл. 4 и на рис. 9.

Таблица 4. Сравнение оптимизаторов и сечений Adam (разрешение 256×256).

Конфигурация	D_{box}	сход.	осц.	расх.	NaN
SGD	1.633 ± 0.041	0.49	0.19	0.06	0.26
SGD+momentum ($\beta = 0.9$)	1.037 ± 0.011	0.82	0.00	0.02	0.16
Adam	1.322 ± 0.054	0.82	0.05	0.14	0.00
RMSprop	1.508 ± 0.068	0.20	0.54	0.26	0.00
Adam, сечение (η, β_1)	1.698 ± 0.071	0.48	0.52	0.00	0.00
Adam, сечение (η, β_2)	1.727 ± 0.073	0.28	0.72	0.00	0.00

В плоскости (η_0, η_1) Adam действительно даёт более гладкую границу, чем SGD: 1.322 против 1.633. Однако наименьшую размерность даёт вовсе не адаптивный метод,




Рис. 9. Карты обучаемости в плоскости (η_0, η_1) для четырёх оптимизаторов. Диапазоны по осям различны и подобраны под собственный порог каждого метода.

а SGD с фиксированной инерцией $\beta = 0.9$: 1.037. RMSprop занимает промежуточное положение (1.508).

Более того, если сечь пространство гиперпараметров вдоль осей самого Adam, картина меняется на противоположную (рис. 10): сечение (η, β_1) даёт 1.698, а (η, β_2) — 1.727, то есть выше, чем у SGD в базовом сечении. Гипотеза о сглаживающем действии адаптивных методов, таким образом, подтверждается лишь частично и требует переформулировки, к чему мы вернёмся в разделе 7.




Рис. 10. Сечения пространства гиперпараметров Adam по β_1 и β_2 .

Отдельного внимания заслуживает структура карт Adam и RMSprop: на них хорошо видны горизонтальные полосы, почти не зависящие от η_0 . Это прямое следствие покоординатной нормализации: величина шага по каждому весу равна приблизительно η независимо от масштаба градиента, поэтому динамика разделяется по слоям, и карта становится почти сепарабельной. Именно эта сепарабельность, а не подавление хаоса как такового, и снижает измеряемую размерность границы в плоскости (η_0, η_1) .

6.5. Случайные и структурированные данные

Таблица 5. Влияние структуры данных ($|\mathcal{D}| = 16$, полный батч, tanh).

Конфигурация	D_{box}	сход.	осц.	расх.	NaN
случайные данные, $ \mathcal{D} = 16$	1.284 ± 0.070	0.39	0.02	0.02	0.57
digits (PCA-16), $ \mathcal{D} = 16$	1.494 ± 0.073	0.34	0.04	0.02	0.60

При переходе от случайных данных к структурированным размерность возрастает: 1.284 против 1.494 (табл. 5, рис. 11). Правдоподобное объяснение состоит в том, что у случайных данных спектр ковариационной матрицы входов близок к вырожденному по масштабу (все собственные значения одного порядка), тогда как у digits после проекции на главные компоненты спектр существенно неоднороден. Многомасштабность целевой




Рис. 11. Границы обучаемости на случайных данных и на наборе digits.

функции — именно тот фактор, который по результатам [7] порождает хаотическое поведение детерминированного градиентного спуска. Фрактальность границы, таким образом, не является артефактом синтетических данных.

6.6. Трёхмерное пространство $(\eta, \beta, \lambda_{wd})$

Трёхмерный эксперимент реализован как набор двумерных сечений (η, β) при четырёх значениях затухания весов (табл. 6, рис. 12).

Таблица 6. Сечения трёхмерного пространства $(\eta, \beta, \lambda_{wd})$.

Конфигурация	D_{box}	сход.	осц.	расх.	NaN
$\lambda_{wd} = 0$	1.616 ± 0.042	0.52	0.20	0.05	0.23
$\lambda_{wd} = 10^{-4}$	1.374 ± 0.055	0.62	0.10	0.05	0.23
$\lambda_{wd} = 10^{-3}$	1.168 ± 0.037	0.24	0.48	0.05	0.23
$\lambda_{wd} = 10^{-2}$	1.381 ± 0.073	0.23	0.48	0.06	0.23

Зависимость немонотонна: $\lambda_{wd} = 0$ даёт 1.616, 10^{-4} — 1.374, 10^{-3} — 1.168, но 10^{-2} — снова 1.381. Содержательно это означает, что умеренная регуляризация сглаживает границу, а при дальнейшем росте λ_{wd} появляется новый эффект: затухание весов начинает конкурировать с обучением, и возникает дополнительная граница между режимом обучения и режимом стягивания весов к нулю, которая сама по себе нерегулярна. Заметно также, что доля осцилляционного режима резко возрастает (с 0.20 до 0.48).

Отсюда следует прямой ответ на вопрос, поставленный в задании: по набору двумерных сечений судить о сложности границы в полном трёхмерном пространстве можно лишь с осторожностью. Немонотонность $D(\lambda_{wd})$ показывает, что сечения не являются «типичными» срезами однородного объекта; каждое сечение характеризует локальную геометрию границы вблизи выбранной плоскости, а не глобальную структуру. Строгое утверждение о размерности трёхмерной границы потребовало бы прямого box-




Рис. 12. Сечения (η, β) при разных значениях λ_{wd} .

counting в трёхмерной сетке, что превышает доступные вычислительные ресурсы: сетка 256^3 при $T = 400$ потребовала бы примерно в 256 раз больше времени, чем одно двумерное сканирование.

6.7. Последовательность зумов

Пять уровней зума вокруг автоматически выбранной точки границы ($\eta^* \approx 0.369$, $\beta^* \approx 0.300$) показаны на рис. 13, измеренные размерности — в табл. 7.

Таблица 7. Размерность границы на разных уровнях зума в плоскости (η, β) .

Уровень	Диапазон η	Диапазон β	D_{box}
0	[0.0117, 11.7]	[0, 0.795]	1.679 ± 0.053
1	[0.0657, 2.08]	[0.0528, 0.548]	1.783 ± 0.064
2	[0.156, 0.876]	[0.177, 0.424]	1.840 ± 0.071
3	[0.24, 0.569]	[0.238, 0.362]	1.840 ± 0.069
4	[0.298, 0.458]	[0.269, 0.331]	1.855 ± 0.065
Медиана			1.840
Стандартное отклонение			0.065

Структура сохраняется на всех пяти уровнях: качественный характер картины не меняется, что и означает самоподобие. Однако, в отличие от предыдущей НИР, где размерность по уровням зума была практически постоянной ($\sigma = 0.009$), здесь наблюдается систематический рост от 1.679 на нулевом уровне до 1.855 на четвёртом с последующим насыщением; медиана составляет 1.840 при стандартном отклонении 0.065.

Причина роста видна из долей режимов: с углублением зума область переполнения исчезает полностью, а доля осцилляционного режима возрастает с 0.26 до 0.63. Иными словами, при увеличении мы попадаем внутрь зоны, где режимы сходимости и колебаний перемешаны на масштабе отдельных узлов сетки, и измеряемое множество перестаёт быть кривой, приближаясь к площадному заполнению ($D \rightarrow 2$). Это не столько свойство границы, сколько указание на предел применимости самой процедуры: box-counting по бинаризованной карте измеряет геометрию перемешанной зоны, а не гладкой кривой. Рис. 14 показывает извлечённые границы на нулевом и четвёртом уровнях.

6.8. Влияние численной точности

Сравнение расчёта в float64 и float32 для одного и того же сечения (η, β) приведено в табл. 8 и на рис. 15.

Крупномасштабная структура совпадает, что подтверждает: наблюдаемая изрезанность не является артефактом численной ошибки. Оценка размерности в одинарной точности оказалась выше (1.716 против 1.616). Это ожидаемо: в хаотической зоне траектории чувствительны к начальным условиям, и ошибки округления в float32




Рис. 13. Последовательность зумов: каждый следующий уровень сужает окно вдвое по $\log \eta$ и по β .




Рис. 14. Извлечённая граница на нулевом и четвёртом уровнях зума.

Таблица 8. Влияние типа точности на оценку размерности.

Конфигурация	D_{box}	сход.	осц.	расх.	NaN
float64	1.616 ± 0.042	0.52	0.20	0.05	0.23
float32	1.716 ± 0.060	0.44	0.28	0.00	0.28




Рис. 15. Одно и то же сечение (η, β) , вычисленное в двойной и одинарной точности.

действуют как дополнительный шум, увеличивая перемешивание режимов вблизи границы. Для измерения размерности двойная точность необходима.

7. Обсуждение

7.1. Сводка результатов

Собранные данные позволяют дать следующие ответы на вопросы, поставленные в разделе 2.

Сохраняется ли фрактальность при добавлении инерции? Да, полностью. Размерность границы в сечении (η, β) равна 1.695 ± 0.033 и совпадает в пределах погрешности с базовой картой (η_0, η_1) , где 1.688 ± 0.035 . Инерция сдвигает границу, меняет соотношение долей режимов, но не делает её гладкой.

Влияние затухания весов и размера батча. Умеренное затухание весов сглаживает границу; уменьшение размера батча, наоборот, увеличивает её изрезанность монотонно ($1.433 \rightarrow 1.568 \rightarrow 1.722$ при $B = 32 \rightarrow 4 \rightarrow 1$). Оба эффекта естественно интерпретируются через многомасштабность целевой функции: регуляризация подавляет мелкомасштабные особенности ландшафта, стохастичность батча их добавляет.

Сглаживают ли адаптивные методы границу? Ответ оказался тоньше, чем предполагала исходная гипотеза, и составляет, на наш взгляд, основной содержательный результат работы.

7.2. О «сглаживании» границы адаптивными методами

Гипотеза задания состояла в том, что адаптивные методы частично сглаживают фрактальную структуру за счёт нормализации градиентов по координатам. Данные подтверждают её в узком смысле и опровергают в широком.

В плоскости (η_0, η_1) Adam действительно даёт меньшую размерность, чем SGD (1.322 против 1.633). Однако наименьшую размерность даёт не адаптивный метод, а SGD с фиксированной инерцией $\beta = 0.9$ (1.037), где никакой покоординатной нормализации нет. Значит, сглаживание обеспечивает не адаптивность как таковая, а усреднение градиента по времени, которое подавляет высокочастотную составляющую динамики и уменьшает чувствительность исхода к малым изменениям шага.

Более того, сглаживание оказывается свойством выбранного сечения, а не оптимизатора. Стоит перерезать пространство гиперпараметров вдоль собственных осей Adam, и граница вновь оказывается предельно изрезанной: 1.698 для (η, β_1) и 1.727 для (η, β_2) — выше, чем у SGD в базовом сечении. Механизм понятен из вида карт Adam и RMSprop (рис. 9): покоординатная нормализация делает величину шага по каждому весу почти независимой от масштаба градиента, из-за чего динамика разделяется по слоям и карта в плоскости (η_0, η_1) становится почти сепарабельной — граница вырождается в набор почти горизонтальных полос. Низкая размерность здесь измеряет сепарабельность, а не отсутствие хаоса. Как только сечение выбирается так, что сепарабельность не работает (оси β_1, β_2 управляют самим усреднением), фрактальность проявляется в полной мере.

Этот вывод согласуется с результатами [2], где фрактальные границы наблюдались именно для моделей, обучаемых Adam, и с [5], где показано, что адаптивные методы обладают собственным аналогом грани устойчивости. Практический смысл: переход на Adam не избавляет от необходимости аккуратного подбора шага обучения, он лишь переносит нерегулярность в другие координаты пространства гиперпараметров.

7.3. Связь с теорией динамики

Наблюдаемая картина хорошо укладывается в схему раздела 4. Для квадратичной модели граница устойчивости — гладкая прямая $\eta\lambda = 2(1 + \beta)$. В карте (η, β) (рис. 6) внешняя граница области переполнения действительно близка к прямой линии, смещающейся с ростом β ; именно она соответствует линейной теории. Вся нерегулярность сосредоточена на внутренней границе — между сходимостью и ограниченными колебаниями. Это в точности та зона, где линейный анализ неприменим: система вышла за порог устойчивости по старшей моде, но не расходится, потому что нелинейность переводит её в область меньшей кривизны (catapult-механизм [6]) или удерживает на грани устойчивости [4]. Исход в этой зоне определяется тонким балансом и потому чувствителен к сколь угодно малым изменениям гиперпараметров — что и порождает фрактальную структуру.

Бифуркационная диаграмма (рис. 2) показывает механизм в чистом виде: при росте η нелинейная скалярная система проходит через каскад удвоения периода и хаос, и рост β смещает каскад в область меньших шагов. Показательно, что для линейной задачи инерция допустимый шаг расширяет (следствие 2), а для нелинейной — сужает окно регулярного поведения. Именно это расхождение между линейным предсказанием и нелинейной реальностью и есть источник изрезанности границы.

7.4. Ограничения исследования

Результаты следует интерпретировать с учётом ряда существенных ограничений.

Зависимость оценки размерности от разрешения сетки. Это наиболее серьёзное методологическое ограничение. Одна и та же конфигурация, посчитанная на разных сетках, даёт систематически разные оценки (табл. 9): от 1.511 на сетке 128×128 до 1.688 на 512×512 . Причина в том, что более мелкая сетка разрешает более тонкие складки границы, а диапазон доступных масштабов ε в формуле (5) всегда ограничен снизу размером пикселя. Приводимая величина σ_D отражает только качество линейной регрессии и эту систематику не учитывает. Поэтому сравнивать между собой корректно только карты одинакового разрешения, что в настоящей работе и делается: все сравнения оптимизаторов, сечений и датасетов выполнены на сетках 256×256 .

Таблица 9. Зависимость оценки размерности от разрешения сетки для одной и той же конфигурации ($\tanh$, (η_0, η_1) , $|\mathcal{D}| = 1$).

Разрешение сетки	D_{box}	доля сходимости
128×128	1.511 ± 0.051	0.49
256×256	1.633 ± 0.041	0.49
512×512	1.688 ± 0.035	0.49

Различие окон сканирования. Порог устойчивости зависит от активации, объёма данных и оптимизатора, поэтому окна по η подбирались индивидуально. Как следствие, доля площади карты, занятая границей, различна для разных экспериментов, а измеряемая размерность от неё зависит. Сравнение размерностей между оптимизаторами является, строго говоря, качественным; количественно надёжны лишь сравнения внутри одного семейства окон (например, ряд по размеру батча, где окно фиксировано).

Граница как зона, а не кривая. В отличие от классических фракталов, где граница — одномерная кривая, в наших картах переход между сходимостью и колебаниями представляет собой протяжённую зону, в которой режимы перемешаны на масштабе отдельных узлов сетки. Значения $D \approx 1.85$, полученные на глубоких уровнях зума, отражают приближение этой зоны к площадному заполнению, а не структуру гладкой кривой. Формально box-counting применим и здесь, но интерпретировать результат как «размерность границы» следует с осторожностью.

Артефакт критерия сходимости для ReLU. Критерий, унаследованный от предыдущей НИР (средний нормализованный loss меньше единицы), засчитывает как

успешное обучение вырожденный случай: при большом шаге все ReLU-нейроны переходят в область отрицательных предактиваций, градиент обнуляется, обучение останавливается, и loss замирает на постоянном уровне ниже начального. Мёртвая сеть формально классифицируется как сошедшаяся. Именно этим объясняется доля сходимости 0.99 для ReLU при $|D| = 1$ во всём диапазоне вплоть до $\eta = 10^4$. Для корректного сравнения активаций пришлось использовать набор из 32 примеров, где такой коллапс менее вероятен. Более строгий критерий (требование снижения loss в заданное число раз) устранил бы артефакт, но сделал бы результаты несопоставимыми с предыдущей работой.

Ограниченность числа итераций. Все эксперименты выполнены при $T = 400$. Классификация режимов зависит от T : траектория, помеченная как осциллирующая, могла бы при большем T выйти на сходимость. Это смещает границу в сторону области колебаний, но, судя по устойчивости картины при переходе от $T = 300$ к $T = 500$ на этапе калибровки, не меняет качественных выводов.

Простота архитектуры и объём данных. Исследована однослойная сеть с 512 параметрами на выборках объёмом до 32 примеров. Перенос выводов на глубокие архитектуры и полноразмерные датасеты требует отдельной проверки; косвенным аргументом в пользу переносимости служит работа [2], где явление наблюдалось для трансформеров.

Отсутствие прямого трёхмерного box-counting. Трёхмерное пространство исследовано набором двумерных сечений; как показано в разделе 6.6, немонотонность $D(\lambda_{wd})$ не позволяет по сечениям надёжно судить о размерности трёхмерной границы.

7.5. Практические следствия

Из полученных данных вытекает несколько практических соображений. Во-первых, автоматический подбор шага обучения принципиально осложнён тем, что на любом масштабе рядом с работающей конфигурацией находится неработающая; это относится и к SGD, и к Adam, только для последнего нерегулярность проявляется в других координатах. Во-вторых, наилучшие по скорости конфигурации систематически лежат вблизи границы, что согласуется с концепцией грани устойчивости и означает, что консервативный выбор шага заведомо жертвует скоростью. В-третьих, умеренная L_2 -регуляризация и увеличение размера батча делают ландшафт обучаемости более предсказуемым — это может быть самостоятельным аргументом в их пользу помимо влияния на обобщающую способность.

8. Заключение

8.1. Достигнутые результаты

В работе исследована структура границы обучаемости однослойной нейронной сети в многомерном пространстве гиперпараметров, включающем шаг обучения, инерцию, затухание весов, размер мини-батча и параметры адаптивных оптимизаторов. Получены следующие результаты.

1. **Теоретический мини-результат.** Для квадратичной функции $L(w) = \frac{1}{2}\lambda w^2$ градиентный спуск с инерцией записан в виде двумерного линейного отображения с матрицей перехода $M = \begin{pmatrix} 1-\eta\lambda & -\eta\beta \\ \lambda & \beta \end{pmatrix}$, для которой $\det M = \beta$ и $\text{tr } M = 1 + \beta - \eta\lambda$. Доказано (предложение 1), что область устойчивости есть $0 < \eta\lambda < 2(1 + \beta)$ при $|\beta| < 1$, то есть инерция расширяет допустимый шаг обучения вплоть до двукратного по сравнению с обычным градиентным спуском; при комплексных собственных значениях скорость сходимости равна $\sqrt{\beta}$ и не зависит от кривизны. Результат подтверждён численно.
2. **Репликация.** Воспроизведён базовый эксперимент предыдущей НИР; для активации $\tanh$ на сетке 512×512 получено $D_{\text{box}} = 1.688 \pm 0.035$. Показано, что сравнение активаций требует индивидуального выбора окна сканирования, поскольку порог устойчивости у них различается на порядки.
3. **Фрактальность сохраняется при добавлении инерции.** В сечении (η, β) получено $D_{\text{box}} = 1.695 \pm 0.033$, что совпадает с базовой картой в пределах погрешности.
4. **Влияние регуляризации и батча.** Затухание весов сглаживает границу (1.153 против 1.633 при том же разрешении), уменьшение размера батча — увеличивает изрезанность монотонно: 1.433, 1.568, 1.722 при $B = 32, 4, 1$.
5. **Сравнение оптимизаторов.** Получены размерности 1.633 (SGD), 1.037 (SGD с инерцией $\beta = 0.9$), 1.322 (Adam), 1.508 (RMSprop). Гипотеза о сглаживающем действии адаптивных методов подтверждается лишь частично: сглаживание обеспечивает усреднение градиента по времени, а не покоординатная нормализация, и является свойством выбранного сечения — в сечениях (η, β_1) и (η, β_2) сам Adam даёт 1.698 и 1.727.
6. **Структурированные данные.** Переход от случайных данных к набору digits увеличивает размерность границы ($1.284 \rightarrow 1.494$); фрактальность не является артефактом синтетических данных.
7. **Трёхмерное пространство.** Построены четыре сечения (η, β) при разных λ_{wd} ; зависимость размерности от λ_{wd} немонотонна, что показывает ограниченность вывода о трёхмерной границе по набору двумерных сечений.
8. **Воспроизводимый инструментарий.** Реализована ансамблевая векторизованная

схема сканирования, позволяющая обсчитывать сетки 512×512 на одном ядре CPU за единицы минут, с фиксацией seed, точности и полным сохранением параметров каждого запуска.

8.2. Научная и практическая значимость

Основной содержательный вывод состоит в том, что фрактальность границы обучаемости — свойство не конкретного оптимизатора, а самой нелинейной динамики обучения вблизи порога устойчивости. Переход к более сложным оптимизаторам меняет расположение границы и то, в каких координатах проявляется её нерегулярность, но не устраняет её. Это уточняет ожидание, согласно которому адаптивные методы «сглаживают» ландшафт обучаемости.

Практически это означает, что чувствительность к шагу обучения не может быть устранена выбором оптимизатора и должна учитываться в процедурах автоматического подбора гиперпараметров; при этом умеренная L_2 -регуляризация и увеличение размера батча объективно повышают предсказуемость обучения.

8.3. Ограничения

Основные ограничения перечислены в разделе 7.4. Кратко: оценка размерности систематически зависит от разрешения сетки, что допускает сравнение лишь внутри одного разрешения; окна сканирования подбирались индивидуально, что делает межоптимизаторное сравнение качественным; переход между режимами представляет собой протяжённую зону перемешивания, а не кривую; критерий сходимости, унаследованный от предыдущей работы, засчитывает как успех вырожденный случай «мёртвых» ReLU-нейронов; исследована лишь однослойная сеть при $T = 400$ итерациях.

8.4. Направления дальнейшей работы

1. Прямой трёхмерный box-counting в пространстве $(\eta, \beta, \lambda_{wd})$ вместо набора сечений; это требует примерно двух порядков дополнительного машинного времени либо адаптивного разрешения сетки вблизи границы.
2. Уточнение критерия обучаемости: замена порога «loss ниже начального» на требование снижения loss в заданное число раз с отдельной классификацией вырожденных состояний (мёртвые нейроны, стягивание весов к нулю регуляризацией).
3. Проверка устойчивости выводов к числу итераций: измерение $D_{\text{box}}(T)$ и определение, сходится ли оценка при $T \rightarrow \infty$.
4. Перенос сравнения оптимизаторов на глубокие архитектуры и на полноразмерные датасеты, включая проверку сепарабельности карт Adam, обнаруженной в настоящей работе.

5. Развязанное затухание весов (AdamW) [15] как отдельное сечение: интересно, сохраняется ли сглаживающий эффект при развязке.
6. Аналитическое описание внутренней границы (между сходимостью и ограниченными колебаниями) для двухслойной линейной сети, где динамика допускает явный анализ.

Список литературы

- [1] *Sohl-Dickstein J.* The boundary of neural network trainability is fractal // arXiv preprint arXiv:2402.06184. — 2024. — URL: <https://arxiv.org/abs/2402.06184> (дата обращения: 20.05.2026).
- [2] *Torkamandi B. [и др.]* Mapping the edge of chaos: fractal-like boundaries in the trainability of decoder-only transformer models // arXiv preprint arXiv:2501.04286. — 2025. — URL: <https://arxiv.org/abs/2501.04286> (дата обращения: 20.05.2026).
- [3] *Liu Y., Arnould L., Sohl-Dickstein J.* Complex fractal trainability boundary can arise from trivial non-convexity // arXiv preprint arXiv:2406.13971. — 2024. — URL: <https://arxiv.org/abs/2406.13971> (дата обращения: 20.05.2026).
- [4] *Cohen J. M., Kaur S., Li Y., Kolter J. Z., Talwalkar A.* Gradient descent on neural networks typically occurs at the edge of stability // International Conference on Learning Representations (ICLR). — 2021. — URL: <https://arxiv.org/abs/2103.00065> (дата обращения: 20.05.2026).
- [5] *Cohen J. M. [и др.]* Adaptive gradient methods at the edge of stability // arXiv preprint arXiv:2207.14484. — 2022. — URL: <https://arxiv.org/abs/2207.14484> (дата обращения: 20.05.2026).
- [6] *Lewkowycz A., Bahri Y., Dyer E., Sohl-Dickstein J., Gur-Ari G.* The large learning rate phase of deep learning: the catapult mechanism // arXiv preprint arXiv:2003.02218. — 2020. — URL: <https://arxiv.org/abs/2003.02218> (дата обращения: 20.05.2026).
- [7] *Kong L., Tao M.* Stochasticity of deterministic gradient descent: large learning rate for multiscale objective function // Advances in Neural Information Processing Systems (NeurIPS). — 2020. — URL: <https://proceedings.neurips.cc/paper/2020/file/1b9a80606d74d3da6db2f1274557e644-Paper.pdf> (дата обращения: 20.05.2026).
- [8] *Chen X., Balasubramanian K., Ghosal P., Agrawalla B.* From stability to chaos: analyzing gradient descent dynamics in quadratic regression // arXiv preprint arXiv:2310.01687. — 2023. — URL: <https://arxiv.org/abs/2310.01687> (дата обращения: 20.05.2026).
- [9] *Feigenbaum M. J.* Quantitative universality for a class of nonlinear transformations // Journal of Statistical Physics. — 1978. — Т. 19, № 1. — С. 25–52. — DOI: 10.1007/BF01020332.
- [10] *Li T.-Y., Yorke J. A.* Period three implies chaos // The American Mathematical Monthly. — 1975. — Т. 82, № 10. — С. 985–992. — DOI: 10.2307/2318254.
- [11] *Поляк Б. Т.* О некоторых способах ускорения сходимости итерационных методов // Журнал вычислительной математики и математической физики. — 1964. — Т. 4, № 5. — С. 791–803.

- [12] *Нестеров Ю. Е.* Метод решения задачи выпуклого программирования со скоростью сходимости $O(1/k^2)$ // Доклады АН СССР. — 1983. — Т. 269, № 3. — С. 543–547.
- [13] *Kingma D. P., Ba J.* Adam: a method for stochastic optimization // International Conference on Learning Representations (ICLR). — 2015. — URL: <https://arxiv.org/abs/1412.6980> (дата обращения: 20.05.2026).
- [14] *Tieleman T., Hinton G.* Lecture 6.5—RMSprop: divide the gradient by a running average of its recent magnitude // COURSERA: Neural Networks for Machine Learning. — 2012.
- [15] *Loshchilov I., Hutter F.* Decoupled weight decay regularization // International Conference on Learning Representations (ICLR). — 2019. — URL: <https://arxiv.org/abs/1711.05101> (дата обращения: 20.05.2026).
- [16] *Bottou L., Curtis F. E., Nocedal J.* Optimization methods for large-scale machine learning // SIAM Review. — 2018. — Т. 60, № 2. — С. 223–311. — DOI: 10.1137/16M1080173.
- [17] *Smith S. L., Kindermans P.-J., Ying C., Le Q. V.* Don't decay the learning rate, increase the batch size // International Conference on Learning Representations (ICLR). — 2018. — URL: <https://arxiv.org/abs/1711.00489> (дата обращения: 20.05.2026).
- [18] *Goodfellow I., Bengio Y., Courville A.* Deep Learning. — Cambridge, MA: MIT Press, 2016. — 800 с. — URL: <http://www.deeplearningbook.org> (дата обращения: 20.05.2026).
- [19] *Falconer K.* Fractal Geometry: Mathematical Foundations and Applications. — 3rd ed. — Chichester: Wiley, 2014. — 400 с.
- [20] *Mandelbrot B. B.* The Fractal Geometry of Nature. — New York: W. H. Freeman and Company, 1982. — 468 с.
- [21] *Strogatz S. H.* Nonlinear Dynamics and Chaos: With Applications to Physics, Biology, Chemistry, and Engineering. — 2nd ed. — Boulder, CO: Westview Press, 2015. — 513 с.
- [22] *Gostick J. T. [u dp.]* PoreSpy: a Python toolkit for quantitative analysis of porous media images // Journal of Open Source Software. — 2019. — Т. 4, № 37. — С. 1296. — URL: https://porespy.org/examples/metrics/tutorials/computing_fractal_dim.html (дата обращения: 20.05.2026).
- [23] *Harris C. R. [u dp.]* Array programming with NumPy // Nature. — 2020. — Т. 585. — С. 357–362. — DOI: 10.1038/s41586-020-2649-2.
- [24] *Virtanen P. [u dp.]* SciPy 1.0: fundamental algorithms for scientific computing in Python // Nature Methods. — 2020. — Т. 17. — С. 261–272. — DOI: 10.1038/s41592-019-0686-2.
- [25] *Pedregosa F. [u dp.]* Scikit-learn: machine learning in Python // Journal of Machine Learning Research. — 2011. — Т. 12. — С. 2825–2830.

- [26] *van der Walt S. [u dp.]* scikit-image: image processing in Python // PeerJ. — 2014. — T. 2. — C. e453. — DOI: 10.7717/peerj.453.

А. Исходный код

Полный исходный код, конфигурации и сохранённые результаты доступны в репозитории проекта:

https://github.com/obilka/fractal_hyperparams_project

Структура каталогов описана в приложении В. Ниже приведены ключевые фрагменты.

А.1. Ансамблевая итерация обучения

Основной приём реализации — одновременное обучение всех узлов сетки гиперпараметров как ансамбля независимых сетей. Веса хранятся с ведущей осью G (номер конфигурации), гиперпараметры транслируются по осям весов.

Листинг 1. Прямой и обратный проход для ансамбля сетей

```
1 H = np.einsum("nd,ghd->gnh", Xb, W0, optimize=True)
2 Ha = _act(H, cfg.activation)
3 out = np.einsum("gnh,goh->gno", Ha, W1, optimize=True)
4 R = out - Yb
5 loss = np.einsum("gno,gno->g", R, R) / (Nb * d_out)
6
7 # ручноеобратноеопространение
8 go = (2.0 / (Nb * d_out)) * R
9 gW1 = np.einsum("gno,gnh->goh", go, Ha, optimize=True)
10 gha = np.einsum("gno,goh->gnh", go, W1, optimize=True)
11 gh = gha * _act_grad(H, Ha, cfg.activation)
12 gW0 = np.einsum("gnh,nd->ghd", gh, Xb, optimize=True)
13
14 # L2регуляризация- (weight decay)
15 gW0 = gW0 + wd * W0
16 gW1 = gW1 + wd * W1
```

А.2. Правила обновления

Листинг 2. Реализация четырёх оптимизаторов

```
1 if opt == "sgd":
2     W0 -= lr0 * gW0
3     W1 -= lr1 * gW1
4 elif opt == "momentum":
5     M0 = beta * M0 + gW0
6     M1 = beta * M1 + gW1
7     W0 -= lr0 * M0
8     W1 -= lr1 * M1
9 elif opt == "rmsprop":
10    V0 = b2 * V0 + (1 - b2) * gW0 * gW0
```

```

11     V1 = b2 * V1 + (1 - b2) * gw1 * gw1
12     W0 -= lr0 * gw0 / (np.sqrt(V0) + eps)
13     W1 -= lr1 * gw1 / (np.sqrt(V1) + eps)
14 elif opt == "adam":
15     M0 = b1 * M0 + (1 - b1) * gw0
16     V0 = b2 * V0 + (1 - b2) * gw0 * gw0
17     bc1, bc2 = 1 - np.power(b1, t + 1), 1 - np.power(b2, t + 1)
18     W0 -= lr0 * (M0 / bc1) / (np.sqrt(V0 / bc2) + eps)
19     # аналогично для второго слоя

```

А.3. Классификация режимов

Листинг 3. Классификация траектории на четыре режима

```

1 m20      = tail[:, -TAIL_SHORT:].mean(axis=1)
2 m20_first = tail[:, :TAIL_SHORT].mean(axis=1)
3 rel      = tail.std(axis=1) / np.maximum(tail.mean(axis=1), 1e-300)
4
5 stabilized = rel < CONV_TOL          # вышла на стационар
6 decreasing = m20 < 0.99 * m20_first  # loss продолжает убывать
7 conv = (m20 < 1.0) & (stabilized | decreasing) & np.isfinite(m20)
8 div  = (stats["max_l"] > DIV_THRESHOLD) | (m20 > DIV_THRESHOLD)
9
10 regime[:] = OSCILLATING
11 regime[conv] = CONVERGED
12 regime[div & ~nonfin] = DIVERGED
13 regime[nonfin] = NONFINITE

```

А.4. Извлечение границы и box-counting

Листинг 4. Морфологическое извлечение границы и оценка размерности

```

1 def extract_boundary(regime):
2     B = (regime == CONVERGED)
3     st = ndimage.generate_binary_structure(2, 1)
4     bnd = np.logical_xor(ndimage.binary_dilation(B, structure=st),
5                          ndimage.binary_erosion(B, structure=st))
6     return skeletonize(bnd) if bnd.sum() > 0 else bnd
7
8 def box_counting_dimension(boundary, min_box=2, max_div=8):
9     s, sizes, counts = min_box, [], []
10    while s <= max(min_box * 2, min(boundary.shape) // max_div):
11        ny = (boundary.shape[0] // s) * s
12        nx = (boundary.shape[1] // s) * s
13        red = boundary[:ny, :nx].reshape(ny // s, s, nx // s, s).any(axis=(1, 3))
14        if red.sum() > 0:
15            sizes.append(s); counts.append(int(red.sum()))

```

```

16         s *= 2
17     coef, cov = np.polyfit(np.log(sizes), np.log(counts), 1, cov=True)
18     return -coef[0], float(np.sqrt(cov[0, 0])), sizes, counts

```

A.5. Теоретический блок

Листинг 5. Спектральный радиус матрицы перехода метода с инерцией

```

1 def momentum_spectral_radius(eta_lambda, beta):
2     x, b = np.asarray(eta_lambda), np.asarray(beta)
3     tr, det = 1.0 + b - x, b
4     disc = tr * tr - 4.0 * det
5     sq = np.sqrt(np.abs(disc))
6     r_real = np.maximum(np.abs((tr + sq) / 2.0), np.abs((tr - sq) / 2.0))
7     return np.where(disc >= 0, r_real, np.sqrt(np.abs(det)))

```

B. Инструкция по воспроизведению

B.1. Структура проекта

src/fractal_hp.py	ядро: модель, оптимизаторы, сканирование, box-counting, теоретический блок
src/run_experiments.py	все эксперименты (стадии A-H), resume-режим
src/make_figures.py	построение всех рисунков
src/make_tables.py	генерация LaTeX-таблиц и макросов с числами
report/main.tex	отчёт (XeLaTeX)
report/sections/	разделы отчёта
report/tables/	таблицы, генерируются автоматически
report/figures/	подпись для титульного листа
outputs/data/	результаты сканирований (.npz) и метаданные (.json)
outputs/figures/	рисунки
run_all.sh	полный цикл: расчёты, рисунки, таблицы, сборка PDF
requirements.txt	версии библиотек

B.2. Требования

Python 3.10 и выше; NumPy, SciPy, scikit-image, scikit-learn, Matplotlib. PyTorch не требуется. Для сборки отчёта — $\text{\TeX}$ Live с XeLaTeX и пакетами polyglossia, fontspec, geometry, setspace, booktabs, subcaption, listings, hyperref; шрифт Liberation Serif. Оперативной памяти достаточно 2 ГБ, расчёты выполняются на CPU.

В.3. Запуск

Листинг 6. Полный цикл воспроизведения

```
1 git clone https://github.com/obilka/fractal_hyperparams_project
2 cd fractal_hyperparams_project
3 pip install -r requirements.txt
4 bash run_all.sh
```

Скрипт последовательно выполняет расчёты (стадии А–Н), строит рисунки и таблицы и собирает PDF. Отдельные стадии запускаются как `python3 src/run_experiments.py` в С. Расчёт поддерживает возобновление: результат каждого блока из 4096 конфигураций сохраняется в файл контрольной точки, и повторный запуск продолжает работу с места остановки, а уже завершённые эксперименты пропускаются.

Суммарное машинное время всех экспериментов — 1.0 ч на одном ядре CPU.

В.4. Фиксация случайности и точности

Seed равен 42 для генерации данных, $42 + 1000$ для инициализации весов и $42 + 7$ для порядка примеров в мини-батчах. Инициализация одинакова для всех узлов сетки в пределах одного эксперимента. Тип данных по умолчанию `float64`; эксперимент G1 выполнен в `float32` для оценки влияния точности. Все параметры запуска сохраняются в JSON рядом с результатом.

С. Дополнительные материалы

Числовые значения, приведённые в тексте и таблицах отчёта, подставляются автоматически из файлов `outputs/data/*.json` через генерируемый файл `report/tables/numbers.tex`. Это гарантирует, что текст отчёта, таблицы и сохранённые результаты расчётов не могут разойтись между собой: при повторном запуске расчётов и пересборке отчёта все числа обновляются согласованно.